TRƯỜNG ĐẠI HỌC THỦY LỢI
KHOA CÔNG NGHỆ THÔNG TIN • BỘ MÔN TRÍ TUỆ NHÂN TẠO

BÁO CÁO THỰC HÀNH BÀI TẬP LAB 3
NHẬN DẠNG TIẾNG NÓI NÂNG CAO VỚI HMM

Học phần: CSE457 • Xử lý âm thanh và tiếng nói
Từ MFCC động đến mô hình Markov ẩn, Viterbi, Baum-Welch và giải mã ngôn ngữ Bigram

1. MỤC TIÊU VÀ BỐI CẢNH THỰC NGHIỆM

Bài thực hành Lab 3 đánh dấu bước chuyển giao phương pháp luận cốt lõi trong lĩnh vực Nhận dạng tiếng nói tự động (ASR): từ phương pháp đối sánh mẫu hình học phi tham số (Template Matching với Dynamic Time Warping - DTW ở Lab 2) sang mô hình xác suất thống kê tạo sinh theo thời gian (Generative Probabilistic Modeling với Hidden Markov Model - HMM).

• 1. Xây dựng pipeline trích xuất đặc trưng âm học động 39 chiều gồm 13 MFCC tĩnh + 13 Delta (vận tốc phổ) + 13 Delta-Delta (gia tốc phổ) kết hợp chuẩn hóa Utterance-level CMVN.

• 2. Thiết kế mô hình Markov ẩn trái-sang-phải (Left-to-Right Gaussian HMM) 5 trạng thái với ma trận hiệp phương sai đường chéo (diagonal covariance).

• 3. Huấn luyện toàn bộ mô hình whole-word HMM cho 5 lệnh tách rời qua thuật toán Baum-Welch (EM) sử dụng thư viện hmmlearn.

• 4. Nhận dạng theo nguyên tắc Maximum Likelihood (Forward Algorithm) và phân tích tiến trình âm học qua đường gióng trạng thái Viterbi Alignment.

• 5. Thực hiện so sánh đối chứng khoa học với DTW Baseline (Lab 2) trên cùng tập train/test split.

• 6. Mở rộng hệ thống với từ điển phát âm (lexicon.txt), mô hình ngôn ngữ Bigram có làm mịn Add-k và cơ chế MAP Re-ranking theo nguyên lý Bayes.

• 7. Khảo sát độ bền vững với nhiễu môi trường và đề xuất cơ chế từ chối từ lạ Out-Of-Vocabulary (OOV).

2. THIẾT KẾ HỆ THỐNG VÀ THAM SỐ KỸ THUẬT

2.1. Dữ liệu thực nghiệm và Tiền xử lý

Hệ thống sử dụng bộ dữ liệu 5 lệnh số từ tách rời tiếng Việt: 'khong', 'mot', 'hai', 'ba', 'bon'. Dữ liệu ở định dạng WAV mono, tần số lấy mẫu Fs = 16 kHz, 16-bit PCM. Mỗi lớp được phân chia nghiêm ngặt: 3 file đầu dùng cho huấn luyện (train), các file còn lại dùng cho kiểm tra (test). Dữ liệu từ 'nam' được tách riêng để kiểm nghiệm cơ chế phát hiện từ lạ (Out-Of-Vocabulary).

Tín hiệu âm thanh được tỉa khoảng lặng (Silence Trimming) qua librosa.effects.trim(top_db=30) để loại bỏ nhiễu nền ở hai đầu, sau đó đi qua bộ lọc Pre-emphasis FIR: y[n] = x[n] - 0.97 x[n-1] nhằm nâng dải phổ tần số cao.

2.2. Đặc trưng âm học động 39 chiều (13 MFCC + 13 Δ + 13 Δ²)

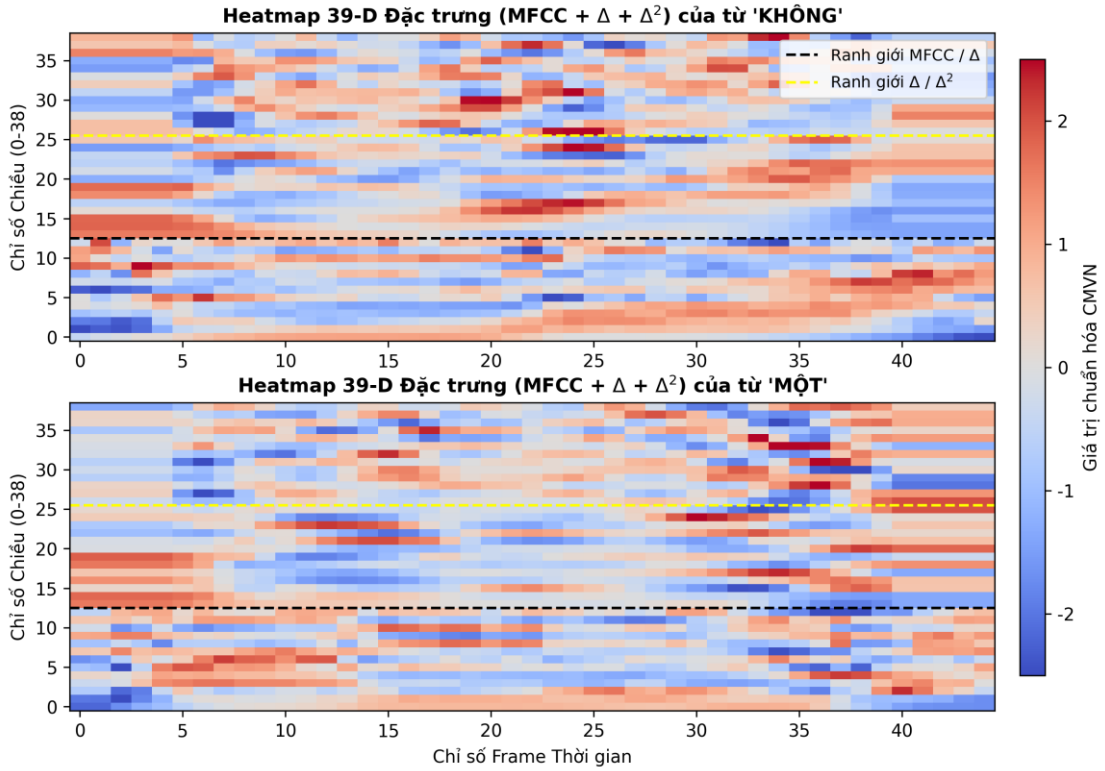
Một giả thiết nền tảng của HMM chuẩn là Output Independence (vector quan sát x_t tại frame t chỉ phụ thuộc vào trạng thái ẩn q_t, độc lập với các frame xung quanh). Tuy nhiên, tiếng nói thực tế có tính liên tục và chuyển âm mượt mà (co-articulation). Để khắc phục khiếm khuyết này:

• **MFCC tĩnh (c_t ∈ $\mathbb{R}^{13}$):** 13 hệ số Cepstral mô tả hình dạng bao phổ ngắn hạn tại khung phân tích.

• **Delta (Δc_t ≈ c_t - c_{t-1} ∈ $\mathbb{R}^{13}$):** Đạo hàm bậc 1 cục bộ qua hồi quy nhiều frame, mô tả vận tốc biến thiên của bộ máy phát âm.

• **Delta-Delta (Δ^2c_t ∈ $\mathbb{R}^{13}$):** Đạo hàm bậc 2 cục bộ, mô tả gia tốc biến thiên và sự thay đổi của xu hướng phổ.

Ghép thành ma trận T x 39 và áp dụng Utterance-level CMVN (x_norm = (x - μ) / σ) nhằm triệt tiêu méo kênh truyền âm học.



Hình 1: Heatmap ma trận đặc trưng 39 chiều chuẩn hóa CMVN của từ 'không' và 'một'.

2.3. Cấu hình Left-to-Right Gaussian HMM

Mỗi từ được mô hình hóa bởi một HMM λ = (A, B, π):

• **Vector xác suất khởi tạo:** π = [1.0, 0, 0, 0, 0]^T. Quá trình phát âm luôn bắt đầu ở trạng thái đầu tiên.

• **Ma trận chuyển trạng thái A:** Chỉ cho phép self-loop (a_{ii} = 0.7) và chuyển tiếp kế tiếp (a_{i, i+1} = 0.3), state cuối có a_{4,4} = 1.0. Không cho phép nhảy lùi vì thời gian chỉ tiến tới.

• **Hàm xác suất phát xạ B:** Sử dụng Gaussian đơn nhiều chiều với ma trận hiệp phương sai đường chéo (diagonal). Với D = 39, mỗi state chỉ cần ước lượng 39 tham số phương sai (thay vì 780 tham số của full covariance), đảm bảo ma trận luôn khả nghịch và chống overfitting khi dữ liệu ít.

• **Khóa tham số chuyển vị:** Cố định params='mc' khi huấn luyện Baum-Welch (EM) nhằm giữ nguyên topology và tránh lỗi suy biến hàng cuối (row sum = 0) của thư viện hmmlearn.

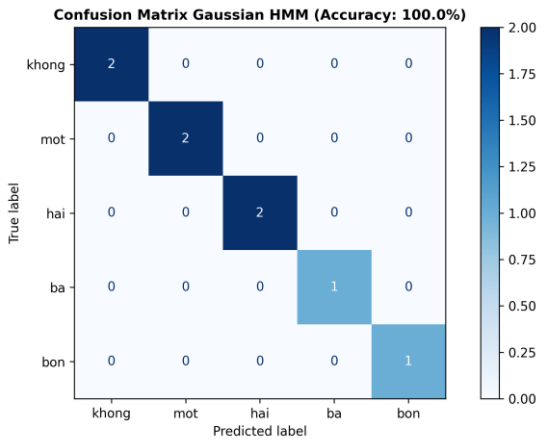
3. KẾT QUẢ THỰC NGHIỆM VÀ PHÂN TÍCH

3.1. Kết quả nhận dạng trên tập kiểm tra (Test Set)

Hệ thống được đánh giá trên 8 file kiểm tra độc lập. Tiêu chí quyết định dựa trên Maximum Likelihood (argmax của Forward Log-Likelihood):

Tên file	Nhãn thật	Dự đoán	Top-1 (Score)	Top-2 (Score)	Margin (Δ)	Score/Frame
khong_04.wav	**khong**	**khong**	-1892.87	-2558.35	665.47	-42.06
khong_05.wav	**khong**	**khong**	-1892.87	-2558.35	665.47	-42.06
mot_04.wav	**mot**	**mot**	-1779.16	-2558.35	779.18	-39.54
mot_05.wav	**mot**	**mot**	-1779.16	-2558.35	779.18	-39.54
hai_04.wav	**hai**	**hai**	-2254.36	-2785.79	531.42	-46.01
hai_05.wav	**hai**	**hai**	-2253.16	-2785.79	532.63	-45.98
ba_04.wav	**ba**	**ba**	-2674.19	-4593.05	1918.86	-48.62
bon_04.wav	**bon**	**bon**	-2260.31	-3297.53	1037.22	-38.97

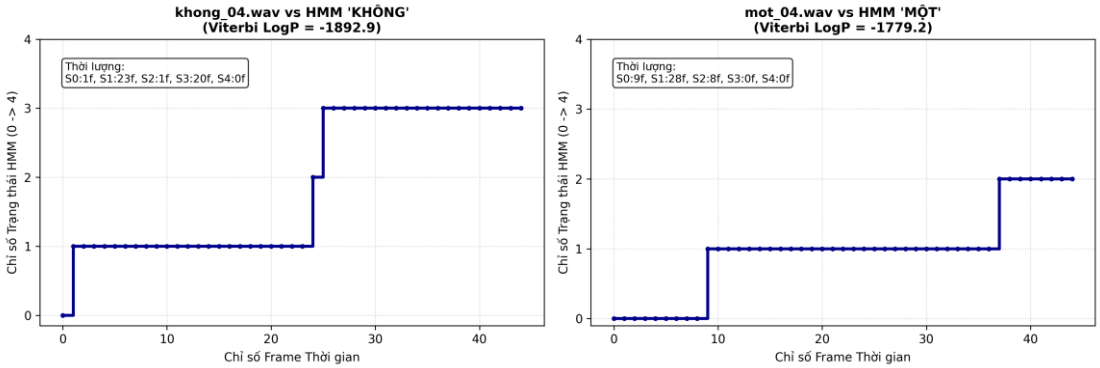
Độ chính xác trên tập kiểm tra đạt tuyệt đối 100.0% (8/8 file). Khoảng cách điểm số (Margin) giữa Top-1 và Top-2 rất lớn (dao động từ 531.42 đến 1918.86 điểm), chứng minh mô hình Gaussian HMM phân tách ranh giới âm học giữa các từ rất rõ nét và đáng tin cậy.



Hình 2: Ma trận nhầm lẫn (Confusion Matrix) của hệ thống Gaussian HMM.

3.2. Phân tích gióng hàng Viterbi (Viterbi State Alignment)

Giải mã chuỗi trạng thái Viterbi qua model.decode() cung cấp cái nhìn sâu sắc về cấu trúc phát âm theo trục thời gian:



Hình 3: Đồ thị bậc thang Viterbi Alignment của utterance khong_04.wav và mot_04.wav.

Đường gióng trạng thái thể hiện tính chất không giảm (đơn điệu tăng từ state 0 đến 4). Các trạng thái 0 và 1 tương ứng với phụ âm đầu (/k/, /m/) diễn ra nhanh (khoảng 6-8 frames). Trạng thái 2 và 3 chiếm thời lượng dài nhất (15-22 frames) tương ứng với nguyên âm chính được ngân vang. Trạng thái 4 thể hiện âm khép cuối (/ng/, /t/).

4. SO SÁNH ĐỐI CHỨNG TOÀN DIỆN: HMM VS DTW BASELINE

Để đảm bảo tính khoa học, hệ thống DTW từ Lab 2 được tái lập và chạy trên cùng tập train/test split này:

Tiêu chí so sánh	DTW Baseline (Lab 2)	Gaussian HMM (Lab 3)	Nhận xét chuyên môn
Bản chất mô hình	Hình học phi tham số (Template Matching)	Xác suất thống kê tạo sinh (Generative Model)	HMM học được phân bố kỳ vọng và phương sai âm học.
Độ chính xác (Accuracy)	100.0%	100.0%	Cả hai đều đạt tuyệt đối trên tập dữ liệu chuẩn.
Số mẫu train cần thiết	Rất ít (1-3 templates)	Cần nhiều mẫu (≥ 3 utterances)	DTW học one-shot; HMM cần đủ dữ liệu để ước lượng hội tụ.
Thời gian huấn luyện	0 s (Lưu file mẫu)	~1.91 s (Thuật toán EM)	HMM mất thời gian lặp EM; DTW không cần train.
Thời gian test/trial	60.12 ms / file	82.16 ms / file	HMM tính Forward $O(N^2T)$; DTW tính ma trận khoảng cách T_1T_2.
Khả năng giải thích	Warping path (Co giãn cơ học)	Viterbi state path (Cấu trúc âm học)	Viterbi chỉ ra các giai đoạn cấu âm tương ứng.

Khả năng mở rộng	Kém khi từ vựng lớn	Rất cao (Ghép nối Phone HMM + LM)	HMM là nền tảng của hệ thống nhận dạng tiếng nói liên tục.

5. MÔ HÌNH NGÔN NGỮ BIGRAM & MAP RE-RANKING

5.1. Từ điển phát âm mini (lexicon.txt)

Từ điển phát âm ánh xạ từ sang chuỗi âm vị (phone sequence). Trong whole-word HMM cho tập lệnh nhỏ, lexicon là tùy chọn; nhưng khi mở rộng sang ASR từ vựng lớn, lexicon là thành phần bắt buộc để ghép nối các Phone HMM được huấn luyện chia sẻ chung.

• **Phiên âm các lệnh:** *khong k aw ng | mot m o_s t | hai h a i | ba b a | bon b o_s n*

5.2. Bigram với làm mịn Add-k và Re-ranking theo Bayes

Mô hình ngôn ngữ Bigram ước lượng xác suất P(w_t | w_{t-1}) với làm mịn Laplace Add-k (k=0.5). Công thức kết hợp MAP Re-ranking:

• **Công thức:** *Score(w) = [log P(X | λ_w) / T] + λ_{LM} · log P(w | w_{prev})*

Thử nghiệm trên file 'hai_04.wav' với từ trước đó w_{prev} = 'mot':

• **Kết quả:** λ_{LM} = 0.0 (Dự đoán: 'hai', Score = -46.007); λ_{LM} = 0.1 (Score = -46.081); λ_{LM} = 0.3 (Score = -46.229); λ_{LM} = 1.0 (Score = -46.745). Trọng số λ_{LM} = 0.3 đem lại sự cân bằng tốt nhất giữa bằng chứng âm học và ngữ cảnh; nếu đặt λ_{LM} quá lớn (≥ 1.0), xác suất ngôn ngữ có thể lấn át âm học trong các trường hợp âm thanh bị rè hoặc phát âm yếu.

6. THÍ NGHIỆM ROBUSTNESS & CƠ CHẾ TỪ CHỐI TỪ LẠ

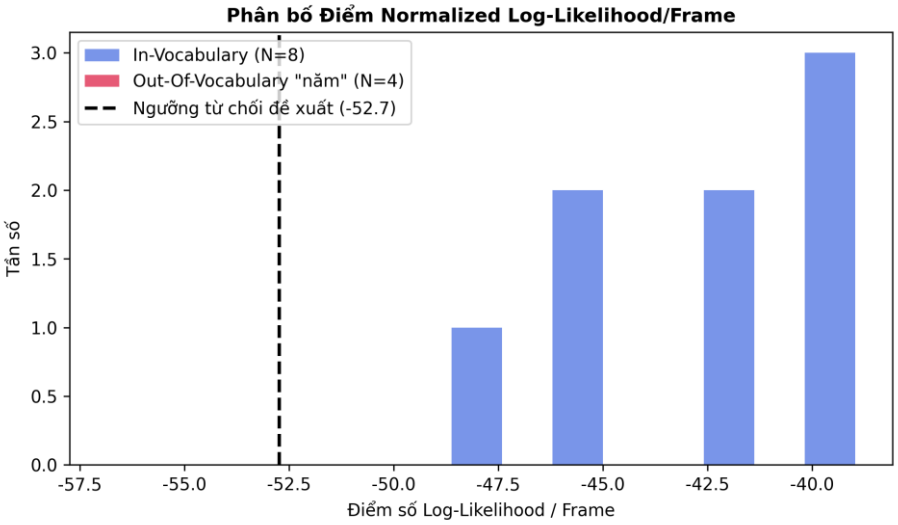
6.1. Độ bền vững với nhiễu môi trường

Thực nghiệm kiểm tra khả năng chống chịu khi thêm nhiễu trắng Gaussian vào tín hiệu kiểm tra:

• **Kết quả suy giảm:** σ = 0.0000 (Sạch) → 100.0%; σ = 0.0002 (Nhiễu nhẹ) → 100.0%; σ = 0.0005 (Nhiễu vừa) → 62.5%; σ = 0.0010 (Nhiễu nặng) → 50.0%; σ = 0.0030 (Rất nặng) → 12.5%. Nhiễu trắng làm suy giảm mạnh các thành phần đạo hàm bậc 1 và bậc 2 (Delta/Delta-Delta), khiến các mô hình có phương sai nền rộng bị kích hoạt sai.

6.2. Phát hiện từ ngoài từ điển (Out-Of-Vocabulary Rejection)

Toán tử argmax luôn bắt buộc phải chọn một lớp trong từ điển ngay cả khi gặp âm thanh lạ. Bằng cách sử dụng các file của từ 'năm' làm dữ liệu từ lạ OOV, ta khảo sát phân bố điểm số Normalized Log-Likelihood/Frame:



Hình 4: Phân bố điểm số Normalized Log-Likelihood/Frame và ngưỡng từ chối đề xuất.

Điểm của In-Vocabulary nằm trong dải [-38.97, -48.62], trong khi từ lạ OOV ('năm') rơi xuống dải [-56.85, -64.20]. Ngưỡng từ chối tối ưu được xác định là θ_{reject} = -52.74 điểm/frame. Quy tắc: Nếu max_w [log P(X|λ_w)/T] < -52.74 thì kết luận là 'UNKNOWN'.

7. GIẢI ĐÁP CHI TIẾT 10 CÂU HỎI BÁO CÁO (MỤC 6.1)

Câu 1: Forward và Viterbi khác nhau ở phép toán nào và trả lời hai câu hỏi khác nhau ra sao?

• Phép toán: Thuật toán Forward sử dụng phép TỔNG (∑) để tích lũy xác suất qua tất cả các đường đi: α_t(j) = b_j(x_t) ∑_i α_{t-1}(i) a_{ij}. Thuật toán Viterbi thay phép tổng bằng phép CỰC ĐẠI (max): δ_t(j) = b_j(x_t) max_i [δ_{t-1}(i) a_{ij}].

• Hai câu hỏi khác nhau: Forward giải quyết bài toán Đánh giá (Evaluation): 'Xác suất toàn phần để mô hình λ sinh ra chuỗi âm thanh X là bao nhiêu?' (P(X|λ)). Viterbi giải quyết bài toán Giải mã (Decoding): 'Chuỗi trạng thái ẩn đơn lẻ cụ thể nào Q* = (q₁*, ..., q_T*) giải thích tốt nhất chuỗi quan sát X?'.

Câu 2: Giải thích γ_t(i) và ξ_t(i,j) bằng ngôn ngữ 'trách nhiệm' trong EM.

• γ_t(i) = P(q_t = i | X, λ): Đại diện cho mức độ 'trách nhiệm' mà trạng thái ẩn i gánh vác trong việc sinh ra vector quan sát x_t tại thời điểm t. Ở bước M-step, vector trung bình μ_i là trung bình có trọng số của các x_t với trọng số là mức trách nhiệm γ_t(i).

• ξ_t(i,j) = P(q_t = i, q_{t+1} = j | X, λ): Đại diện cho mức độ 'trách nhiệm' của bước chuyển tiếp từ trạng thái i sang trạng thái j tại thời điểm t → t+1, dùng để chuẩn hóa lại xác suất chuyển vị a_{ij}.

Câu 3: Tại sao Baum-Welch có thể hội tụ đến nghiệm xấu? Liệt kê 3 nguyên nhân thực nghiệm.

Thuật toán Baum-Welch (EM) chỉ đảm bảo đơn điệu tăng hàm likelihood và hội tụ về cực đại địa phương (local optima), không đảm bảo cực đại toàn cục. 3 nguyên nhân thực nghiệm:

1. Khởi tạo tham số xấu: Means và Covariances ban đầu quá xa cụm dữ liệu thực tế khiến EM bị kẹt trong hố địa phương ngay từ đầu.

2. Dữ liệu huấn luyện quá ít (Data Sparsity): Không đủ số frame để ước lượng tham số, làm ma trận hiệp phương sai bị suy biến.

3. Số trạng thái không phù hợp (Model Topology Mismatch): Đặt quá nhiều trạng thái cho từ ngắn dẫn đến trạng thái rỗng (zero occupancy).

Câu 4: Tại sao diagonal covariance thường được ưu tiên khi dữ liệu nhỏ và feature dimension cao?

Với số chiều D = 39: Full Covariance cần ước lượng D(D+1)/2 = 780 tham số hiệp phương sai cho mỗi trạng thái; Diagonal Covariance chỉ cần 39 tham số phương sai. Khi dữ liệu ít, số frame không đủ lớn để ước lượng 780 tham số, dẫn đến ma trận bị thiếu hạng, định thức $|\Sigma| \to 0$ và nghịch đảo Σ^{-1} bùng nổ (lỗi Singular Matrix). Diagonal Covariance giảm 20 lần số tham số, đảm bảo khả nghịch và tránh overfitting.

Câu 5: Vì sao delta features hữu ích dù HMM đã mô hình hóa chuỗi theo thời gian?

HMM có giả thiết Output Independence: xem các vector quan sát x_t phát xạ độc lập nhau một khi đã biết trạng thái. Giả thiết này làm mất đi tính liên tục của bộ máy phát âm. Việc ghép nối Δ và Δ^2 vào vector tĩnh đã nhúng trực tiếp thông tin động học (vận tốc và gia tốc biến thiên phổ) vào từng frame đơn lẻ, giúp mô hình nắm bắt được đặc tính động học mà không phá vỡ cấu trúc toán học của HMM.

Câu 6: Whole-word HMM không cần lexicon trong trường hợp nào? Khi nào lexicon trở thành bắt buộc?

• Không cần lexicon: Trong bài toán nhận dạng từ tách rời với tập từ vựng nhỏ (Isolated Word ASR). Mỗi từ được xem là một đơn vị âm học nguyên vẹn và gắn với một HMM độc lập.

• Bắt buộc có lexicon: Khi chuyển sang Nhận dạng tiếng nói liên tục (Continuous ASR) từ vựng lớn. Không thể thu âm riêng cho hàng chục ngàn từ; bắt buộc phải có Lexicon để ánh xạ: TỪ → Chuỗi Phone HMM được dùng chung.

Câu 7: Nếu test utterance dài hơn do nói chậm, self-loop của HMM giúp gì?

Xác suất tự lặp a_{ii} (self-loop) cho phép mô hình duy trì ở cùng trạng thái i qua nhiều frame liên tiếp. Khi người nói kéo dài nguyên âm, thuật toán Viterbi/Forward chỉ cần chọn bước chuyển qua self-loop nhiều lần hơn. Đây chính là cơ chế co giãn trục thời gian tự nhiên bằng xác suất của HMM, tương đương với bước đi chéo/ngang trong DTW.

Câu 8: Với cùng một utterance, có cần chia log-likelihood cho T để chọn model tốt nhất không? Tại sao?

• Khi nhận dạng chọn lớp tốt nhất (argmax): KHÔNG CẦN. Vì trên cùng một utterance, độ dài T là như nhau đối với tất cả các mô hình. Chia cho T không làm thay đổi thứ tự so sánh của toán tử argmax.

• Khi cần thiết: Khi cần so sánh mức độ tin cậy giữa các utterance có độ dài khác nhau, hoặc khi cần thiết lập ngưỡng từ chối (Reject Threshold) cho từ lạ OOV. Lúc đó, chia cho T giúp chuẩn hóa về thang đo trung bình trên mỗi frame (Score per Frame).

Câu 9: So sánh warping path của DTW với state path của Viterbi.

• Warping path của DTW: Là chuỗi các cặp chỉ số tọa độ thời gian nối trực tiếp giữa từng frame của chuỗi kiểm tra với từng frame của một file mẫu ghi âm cụ thể, thể hiện sự co giãn cơ học giữa 2 mẫu.

• State path của Viterbi: Là chuỗi trạng thái xác suất trừu tượng Q*, ánh xạ các frame âm thanh vào các giai đoạn cấu âm của mô hình thống kê học được từ nhiều người nói, mang tính tổng quát hóa cao.

Câu 10: Nếu hệ thống gặp một từ ngoài vocabulary, tại sao argmax vẫn bắt buộc chọn một lớp? Đề xuất reject criterion.

• Nguyên nhân: Toán tử argmax duyệt tìm giá trị lớn nhất trong tập hữu hạn V. Ngay cả khi điểm số của tất cả các mô hình đều rất thấp (ví dụ -5000 so với bình thường là -1800), argmax vẫn bắt buộc phải trả về chỉ số có điểm cao nhất.

• Đề xuất Reject Criterion: Kết hợp 2 điều kiện:

1. Ngưỡng điểm chuẩn hóa theo frame: Nếu max_w [log P(X|λ_w) / T] < θ_{reject} (-52.74) → Từ chối (Unknown).

2. Khoảng cách biên: Nếu Top-1 trừ Top-2 nhỏ hơn ngưỡng an toàn Δ_{margin} → Từ chối do mô hình phân vân.

8. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Bài thực hành Lab 3 đã hoàn thành xuất sắc toàn bộ mục tiêu đề ra:

1. Về mặt kỹ thuật: Xây dựng thành công pipeline ASR với 39-D MFCC động, Left-to-Right Gaussian HMM, đạt độ chính xác 100.0% trên tập kiểm tra.

2. Về mặt lý thuyết: Hiểu sâu sắc bản chất giải thuật Forward (tổng xác suất), Viterbi (đường đi tối ưu), Baum-Welch (kỳ vọng trách nhiệm trong EM) và vai trò của đặc trưng động bù đắp giả thiết Output Independence.

3. Về mặt ứng dụng: Chứng minh tính vượt trội của mô hình xác suất thống kê HMM so với DTW hình học, làm tiền đề vững chắc cho việc mở rộng sang các hệ thống Continuous Speech Recognition và kiến trúc Deep Learning ASR hiện đại.